# RecSys Challenge 2025

## Нейросетевые рекомендательные системы 2025 /26, семинар 8

Сергей Макеев

Старший Разработчик,
Отдел Исследований
AI VK

# RecSys Challenge 2025

**На первой половине семинара поговорили про…**

1. Домен, данные
2. Бейзлайн от авторов
3. Наше решение:
   a. Счетчики

**В этой части…**

1. Наше решение:
   b. Трансформер над историей пользователей
   c. Графовая нейросеть TwHIN
   d. Модель, комбинирующая нейросетевые эмбеддинги и счетчики (Deep Cross Network)
2. Закрытые целевые метрики
3. Открытые решения других команд

# Подробнее про наше решение

В статье
**Blending Sequential Embeddings, Graphs, and Engineered Features: 4th Place Solution in RecSys Challenge 2025** [1]

[1] Makeev et al., RecSysChallenge '25: Proceedings of the Recommender Systems Challenge 2025

# Трансформер над историей

**Входные события (упорядочены по времени):**

- Действия над товарами:
  - Добавления в корзину
  - Покупки
  - Удаления из корзины
- Поисковые запросы
- Посещенные веб-страницы

a (cart **a**ddition)
p (**p**urchase)
r (cart **r**emoval)
q (**q**uery)
p (**p**age)

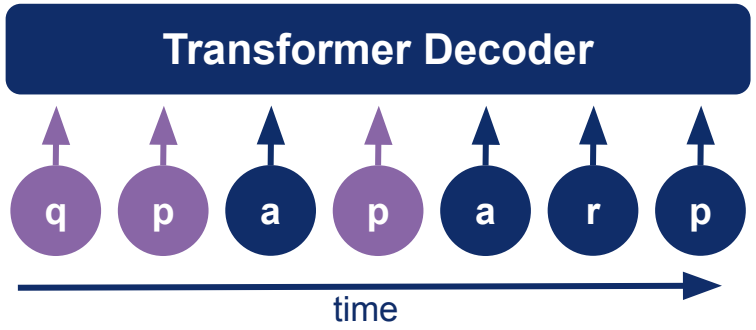

# Трансформер над историей

**Нюансы:**
У каждого пользователя свое число взаимодействий на платформе. Однако в трансформер подаем последовательности ограниченной длины. Поэтому разбиваем истории на **чанки**.

- На обучении:

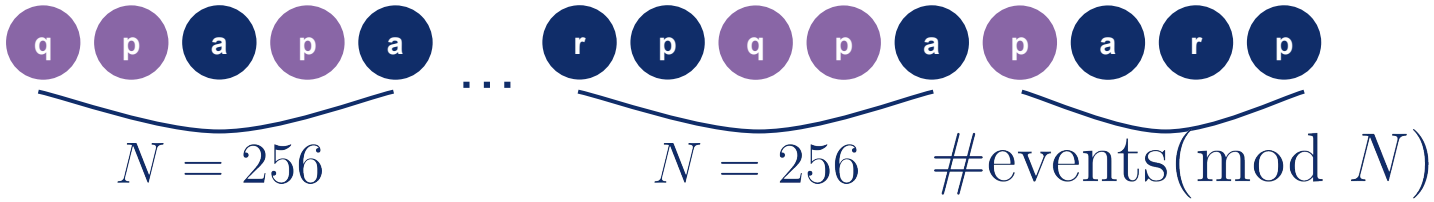


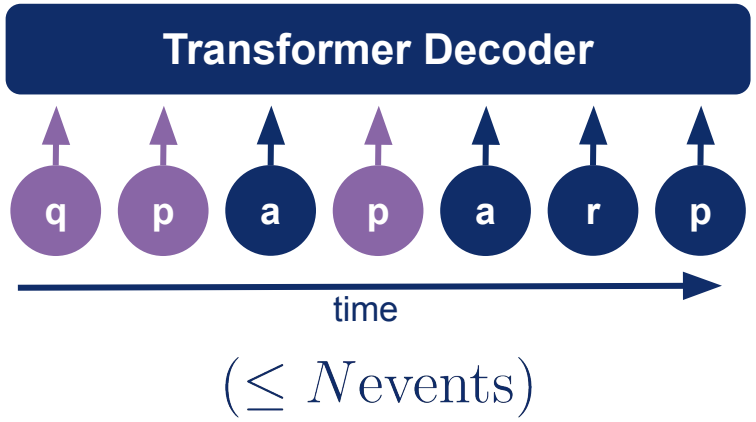


- На инференсе:

# Трансформер над историей

**Кодирование событий**

- Контентные признаки
  - Цена (квантизована в 100 бинов)

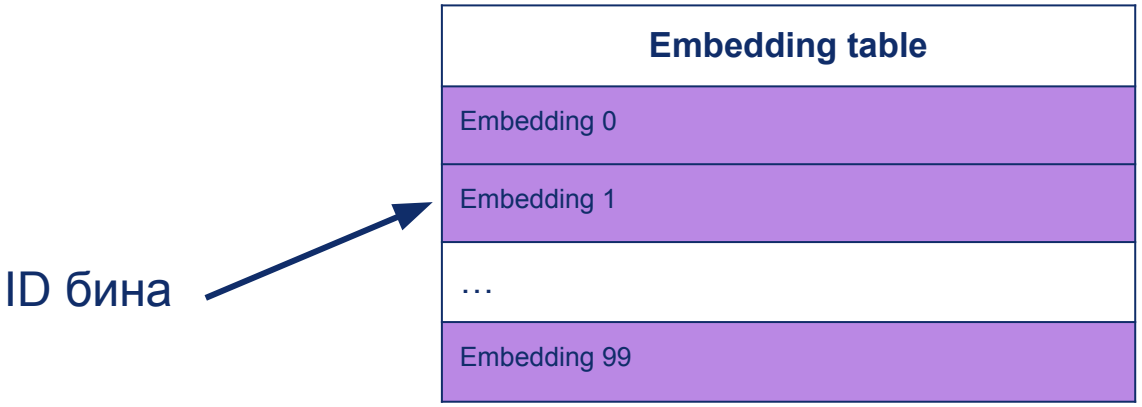


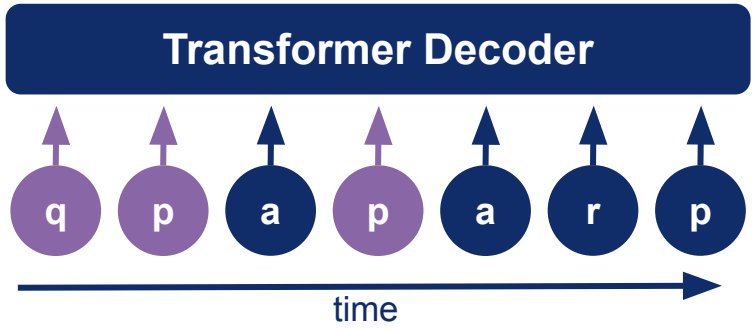


$(\leq N\text{events})$

# Трансформер над историей

**Кодирование событий**

- Контентные признаки
  - Цена (квантизована в 100 бинов)
  - Названия товаров и поисковые запросы

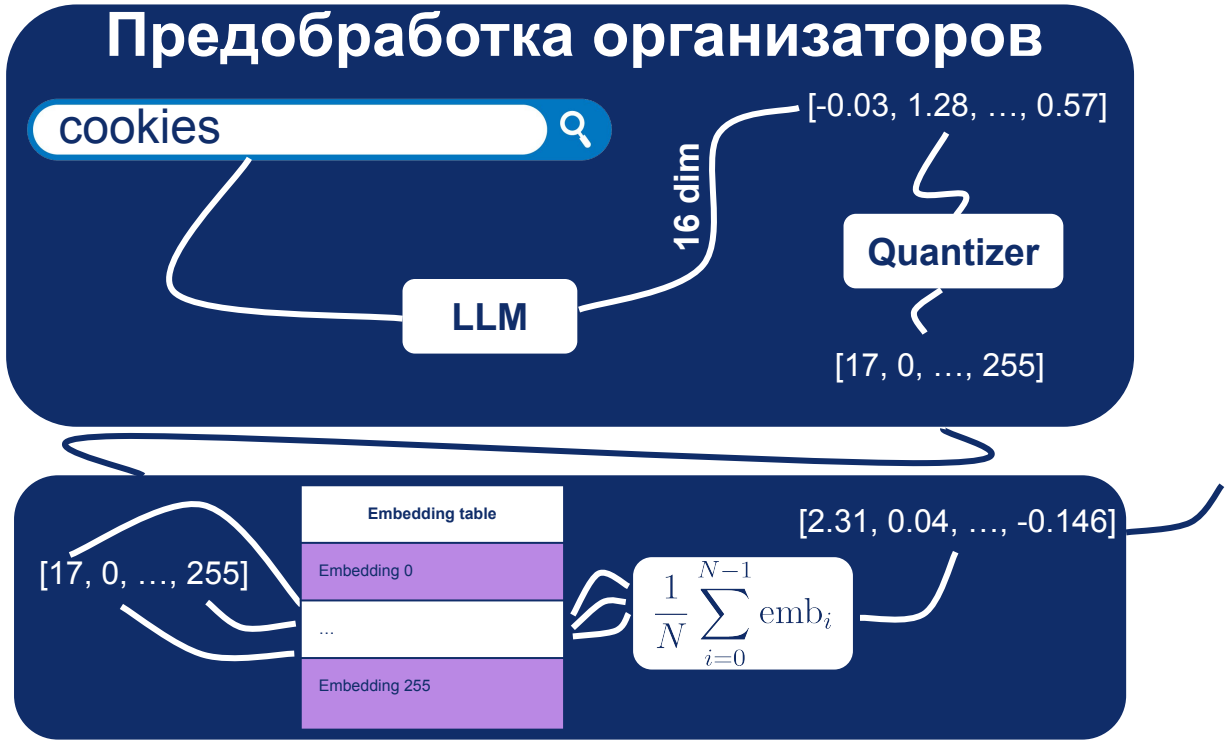


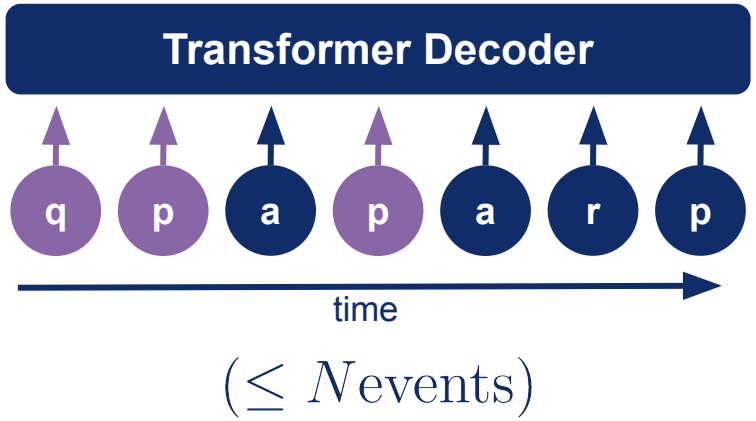

# Трансформер над историей

## Кодирование событий

- Контентные признаки
  - Цена (квантизована в 100 бинов)
  - Названия товаров и поисковые запросы
  - SKU ID, Category ID, URL ID

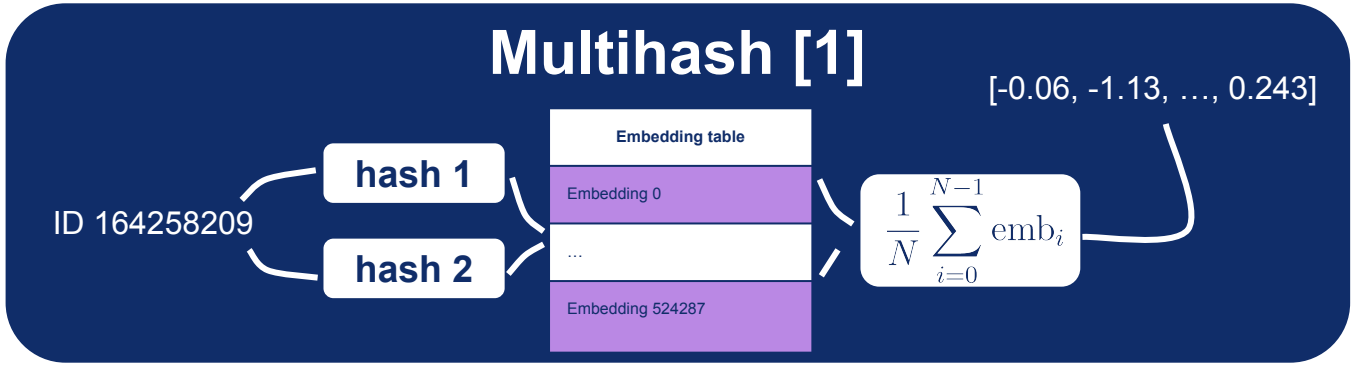


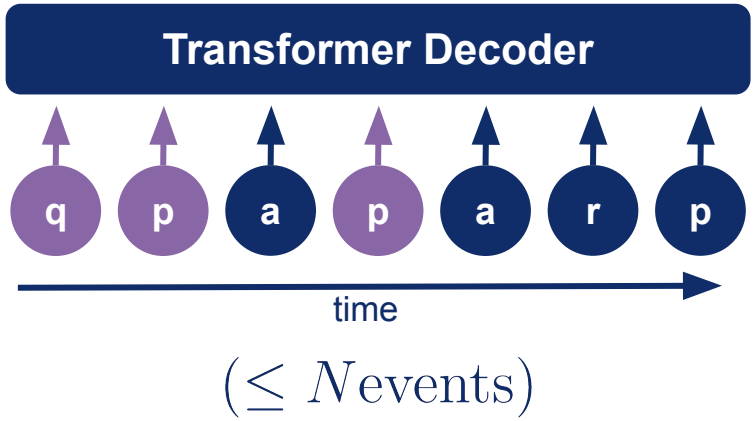


[1] Coleman et al., Unified Embedding: Battle-Tested Feature Representations for Web-Scale ML Systems (Google)

# Трансформер над историей

**Кодирование событий**

- Контентные признаки
  - Цена (квантизована в 100 бинов)
  - Названия товаров и поисковые запросы
  - SKU ID, Category ID, URL ID

  `torch.cat` $\rightarrow$ `torch.nn.Linear(3*256, 256)`

- Контекстные признаки
  - Тип события (q p a r p)
  - Позиция (от $0$ до $N-1$)

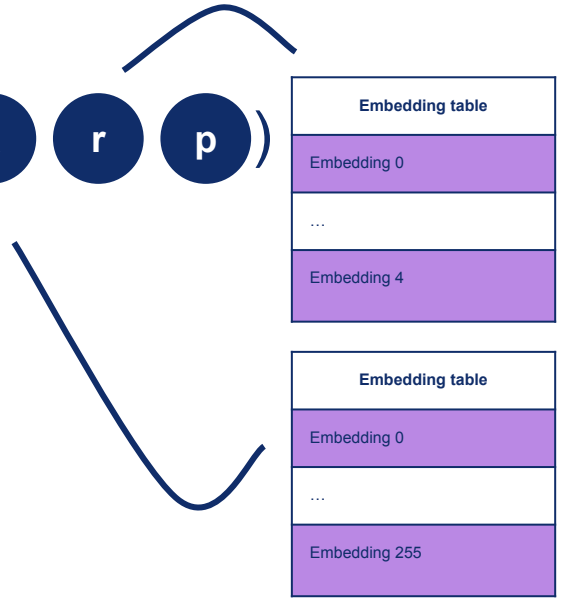


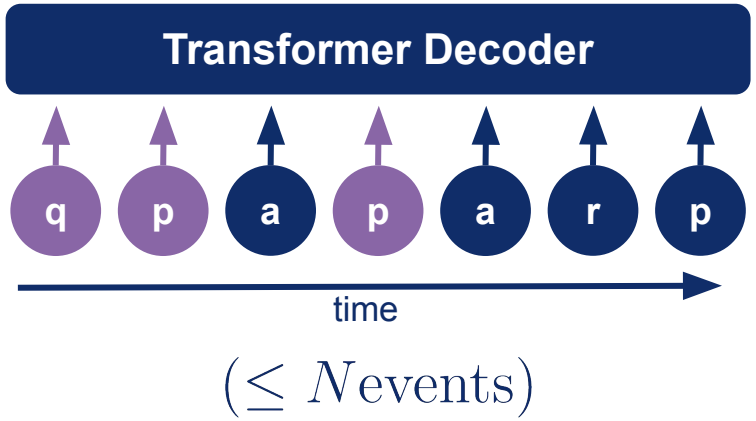

# Трансформер над историей

**Кодирование событий**

- Контентные признаки
  - Цена (квантизована в 100 бинов)
  - Названия товаров и поисковые запросы
  - SKU ID, Category ID, URL ID

  `torch.cat` $\rightarrow$ `torch.nn.Linear(3*256, 256)`

- Контекстные признаки
  - Тип события (q p a r p)
  - Позиция (от $0$ до $N-1$)
  - День недели
  - Час

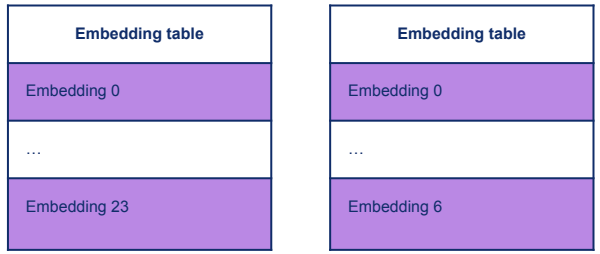


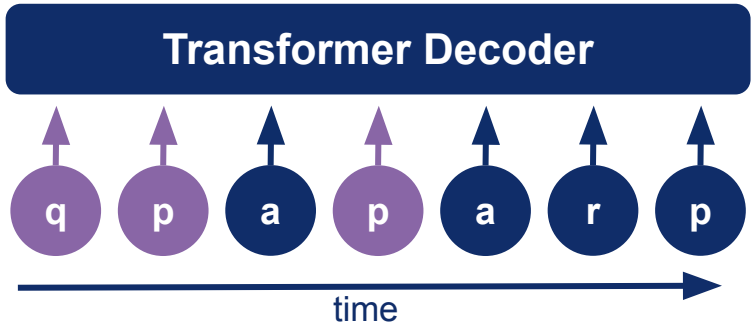


$(\leq N \text{events})$

# Трансформер над историей

**Кодирование событий**

- Контентные признаки
  - Цена (квантизована в 100 бинов)
  - Названия товаров и поисковые запросы
  - SKU ID, Category ID, URL ID

  `torch.cat` $\rightarrow$ `torch.nn.Linear(3*256, 256)`

- Контекстные признаки
  - Тип события (q p a r p)
  - Позиция (от $0$ до $N-1$)
  - День недели
  - Час
  - $\log(1 + \text{hours since last event})$ $\longrightarrow$ `torch.nn.Linear(1, 256)`
  - $\log(1 + \text{days since first event})$ $\longrightarrow$ `torch.nn.Linear(1, 256)`

  `torch.sum`

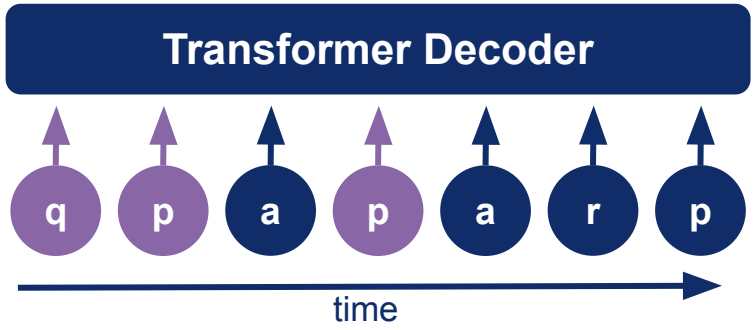


$(\leq N \text{events})$

# Трансформер над историей

## Функции потерь

1. Next Event Type Prediction (NETP) - предсказание типа следующего события

$$\mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) = -\sum_{k=0}^{C-1} y_{i,k} \log \hat{y}_{i,k}, \;\; \mathbf{y} \in \mathbb{R}^{(N-1)\times C}, \hat{\mathbf{y}} \in \mathbb{R}^{(N-1)\times C}$$

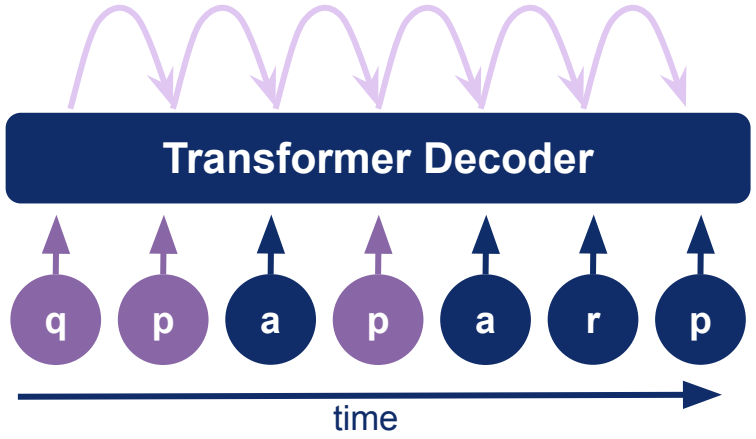


$(\leq N\text{events})$

# Трансформер над историей

## Функции потерь

1. $\mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) = -\sum_{k=0}^{C-1} y_{i,k} \log \hat{y}_{i,k}, \;\; \mathbf{y} \in \mathbb{R}^{(N-1)\times C}, \hat{\mathbf{y}} \in \mathbb{R}^{(N-1)\times C}$

2. Time Delta Prediction (TDP) - предсказываем, через сколько будет следующее взаимодействие

$$\mathcal{L}_{\text{TDP}}(\boldsymbol{\delta}_i, \hat{\boldsymbol{\delta}}_i) = \left(\delta_i - \hat{\delta}_i\right)^2, \;\; \boldsymbol{\delta} \in \mathbb{R}^{N-1}, \hat{\boldsymbol{\delta}} \in \mathbb{R}^{N-1}$$

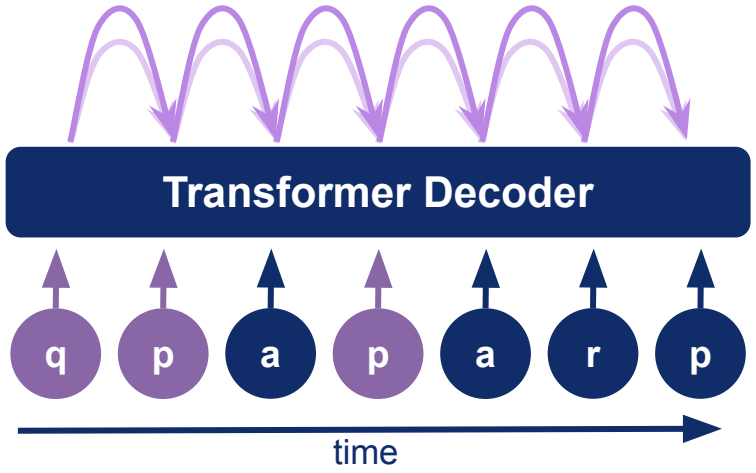


$(\leq N\text{events})$

# Трансформер над историей

## Функции потерь

1. $\mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) = -\sum_{k=0}^{C-1} y_{i,k} \log \hat{y}_{i,k}, \ \mathbf{y} \in \mathbb{R}^{(N-1)\times C}, \hat{\mathbf{y}} \in \mathbb{R}^{(N-1)\times C}$

2. $\mathcal{L}_{\text{TDP}}(\boldsymbol{\delta}_i, \hat{\boldsymbol{\delta}}_i) = \left(\delta_i - \hat{\delta}_i\right)^2, \ \boldsymbol{\delta} \in \mathbb{R}^{N-1}, \hat{\boldsymbol{\delta}} \in \mathbb{R}^{N-1}$

3. Next URL Prediction (NUP) - предсказываем следующую посещенную страницу

$$\mathcal{L}_{\text{NUP}}(u, p) = -\log \frac{e^{\langle g(u), h(p)\rangle/\tau}}{e^{\langle g(u), h(p)\rangle/\tau} + \sum_{i\in\mathcal{N}} e^{\langle g(u), h(d_i)\rangle/\tau}}$$

$\mathcal{N}$- 8192 in-batch негатива

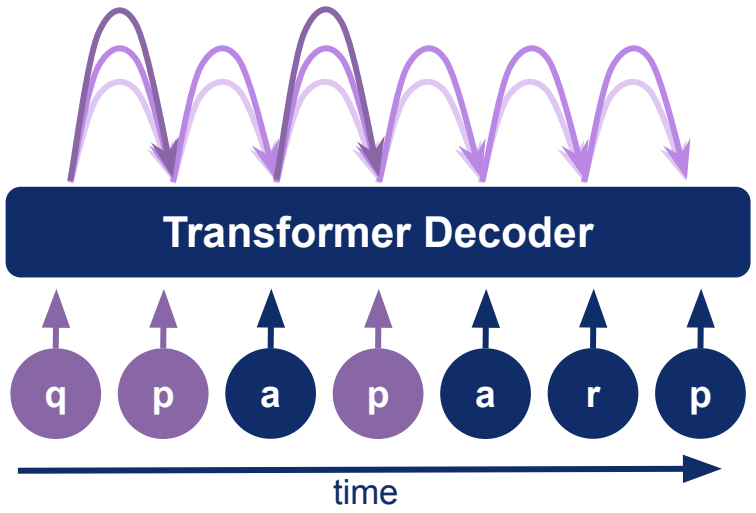


$(\leq N\text{events})$

# Трансформер над историей

## Функции потерь

1. $\mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) = -\sum_{k=0}^{C-1} y_{i,k} \log \hat{y}_{i,k}, \ \mathbf{y} \in \mathbb{R}^{(N-1)\times C}, \hat{\mathbf{y}} \in \mathbb{R}^{(N-1)\times C}$
2. $\mathcal{L}_{\text{TDP}}(\boldsymbol{\delta}_i, \hat{\boldsymbol{\delta}}_i) = \left(\delta_i - \hat{\delta}_i\right)^2, \ \boldsymbol{\delta} \in \mathbb{R}^{N-1}, \hat{\boldsymbol{\delta}} \in \mathbb{R}^{N-1}$
3. $\mathcal{L}_{\text{NUP}}(u, p) = -\log \frac{e^{\langle g(u), h(p)\rangle/\tau}}{e^{\langle g(u), h(p)\rangle/\tau} + \sum_{i\in\mathcal{N}} e^{\langle g(u), h(d_i)\rangle/\tau}}$
4. Next Item Prediction (NIP) - предсказание следующего item ID

$$\mathcal{L}_{\text{NIP}}(u, p) = -w_{up} \log \frac{e^{\langle g(u), h(p)\rangle/\tau}}{\sum_{i\in\mathcal{N}}^{n} e^{\langle g(u), h(d_i)\rangle/\tau - \log Q(d_i)}}$$

$$w_{up} = \text{sg}(1 - P(p \mid u))$$

$\mathcal{N}$ - 8192 in-batch и 8192 uniform негатива

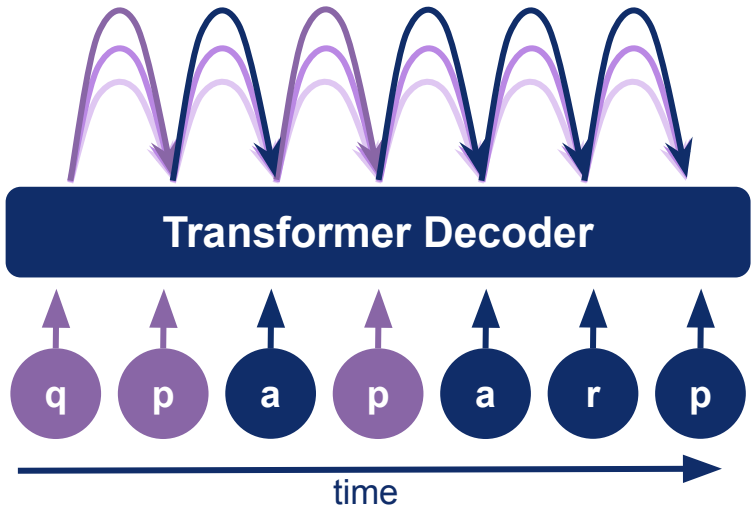


$(\leq N\text{events})$

# Трансформер над историей

## Функции потерь

1. $\mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) = -\sum_{k=0}^{C-1} y_{i,k} \log \hat{y}_{i,k}, \;\; \mathbf{y} \in \mathbb{R}^{(N-1)\times C}, \hat{\mathbf{y}} \in \mathbb{R}^{(N-1)\times C}$

2. $\mathcal{L}_{\text{TDP}}(\boldsymbol{\delta}_i, \hat{\boldsymbol{\delta}}_i) = \left(\delta_i - \hat{\delta}_i\right)^2, \;\; \boldsymbol{\delta} \in \mathbb{R}^{N-1}, \hat{\boldsymbol{\delta}} \in \mathbb{R}^{N-1}$

3. $\mathcal{L}_{\text{NUP}}(u, p) = -\log \dfrac{e^{\langle g(u), h(p)\rangle/\tau}}{e^{\langle g(u), h(p)\rangle/\tau} + \sum_{i\in\mathcal{N}} e^{\langle g(u), h(d_i)\rangle/\tau}}$

4. $\mathcal{L}_{\text{NIP}}(u, p) = -w_{up} \log \dfrac{e^{\langle g(u), h(p)\rangle/\tau}}{\sum_{i\in\mathcal{N}}^{n} e^{\langle g(u), h(d_i)\rangle/\tau - \log Q(d_i)}}$

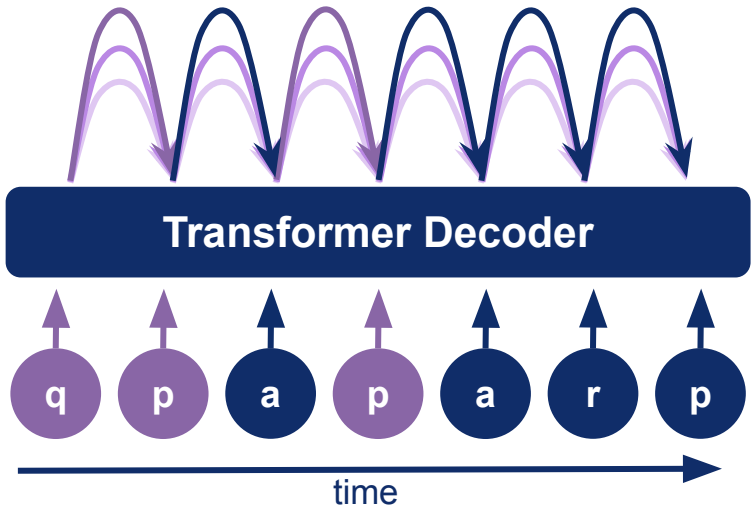


$(\leq N \text{events})$

$$\mathcal{L}_{\text{SeqEnc}} = \frac{1}{N-1}\sum_{i=0}^{N-2} \mathcal{L}_{\text{NETP}}(\mathbf{y}_i, \hat{\mathbf{y}}_i) + \frac{1}{N-1}\sum_{i=0}^{N-2} \mathcal{L}_{\text{TDP}}(\boldsymbol{\delta}_i, \hat{\boldsymbol{\delta}}_i) + \frac{1}{|\mathcal{I}|}\sum_{(u,p)\in\mathcal{I}} \mathcal{L}_{\text{NIP}}(u, p) + \frac{1}{|\mathcal{U}|}\sum_{(u,p)\in\mathcal{U}} \mathcal{L}_{\text{NUP}}(u, p)$$

# Трансформер над историей

**Гиперпараметры:**

- $N = 256$
- `hidden_dim=1024`
- `num_heads=hidden_dim // 64`
- `num_layers=20`
- `dropout=0.1`
- `attn_dropout=0.1`

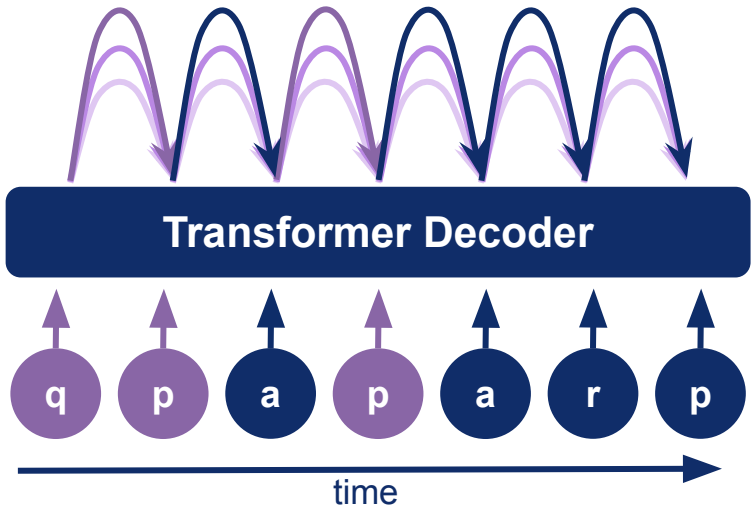


$(\leq N \text{events})$

# Трансформер над историей

## Ablation study

1. Функции потерь

| Objectives | Churn | Category | SKU |
|---|---|---|---|
| All objectives | **0.7404** | **0.8048** | 0.7735 |
| W/o NETP | 0.7379 | 0.8017 | 0.7738 |
| W/o TDP | 0.7369 | 0.8016 | **0.7768** |
| W/o NUP | 0.7391 | 0.8008 | 0.7727 |
| W/o NIP | 0.7374 | 0.7974 | 0.7695 |

2. Размер трансформера

| #params | #layers | hidden_dim | Churn | Category | SKU |
|---|---|---|---|---|---|
| 252M | 20 | 1024 | **0.7404** | **0.8048** | 0.7735 |
| 126M | 10 | 1024 | 0.7397 | 0.8030 | 0.7757 |
| 19M | 6 | 512 | 0.7371 | 0.8013 | **0.7761** |
| 3M | 4 | 256 | 0.7329 | 0.7957 | 0.7712 |

# Графовая нейросеть TwHIN [1]

## Пример. Гетерогенный граф

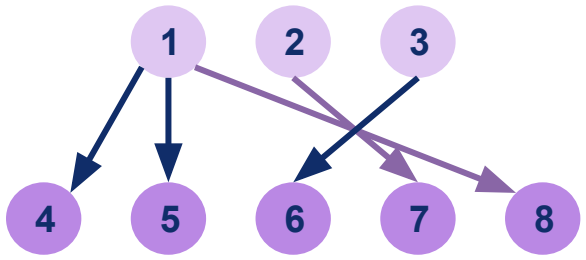


1 2 3 - пользователи

4 5 6 7 8 - товары

- событие типа A (например, лайк)

- событие типа B (например, покупка)

$H = (V, E, T, R, X, \phi, \psi)$ - **гетерогенный граф**

$V$ - множество вершин

$E$ - множество ребер

$T$ - множество типов вершин

$R$ - множество типов ребер

$\phi(v) : V \to T$ - отображение вершины в ее тип

$\psi(e(u, v)) : E \to R$ - отображение ребра в его тип

[1] El-Kishky et al., TwHIN: Embedding the Twitter Heterogeneous Information Network for Personalized Recommendation (Twitter)

# Графовая нейросеть TwHIN

**Задача**: выучить эмбеддинги вершин и ребер

**Кодирование**: учим эмбеддинги всех вершин и всех типов ребер

$$V \cup R \to \Theta \in \mathbb{R}^{(|V|+|R|)\times d}$$

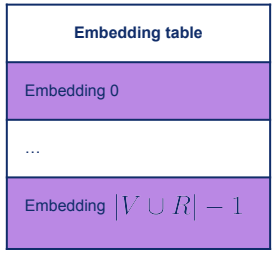


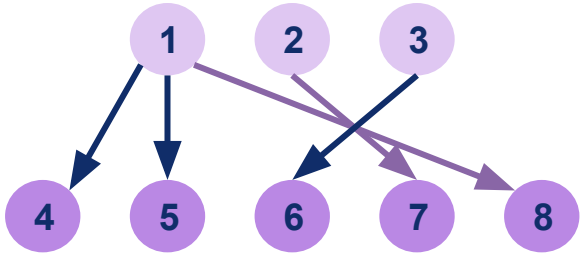


**На какую задачу учимся**: предсказание ребра

вероятность существования ребра: $\sigma(f(e))$, где $f(e) = f(s,r,t) = (\theta_s + \theta_r)^T \theta_t$

**Оптимизируемый функционал:** $arg\max_{\theta} \sum_{e \in E} \left[ \log \sigma(f(e)) + \sum_{e' \in N(e)} \log \sigma(-f(e')) \right]$

где $N(s,r,t) = \{(s,r,t') : t' \in V\} \cup \{(s',r,t) : s' \in V\}$

# Графовая нейросеть TwHIN

**Особенности нашей модели:**

- Ребра - *добавления в корзину* и *покупки*
- Учили эмбеддинги для самых *активных пользователей*
- Вместо кодирования товаров эмбеддингами использовали *предобученный айтемный энкодер* от Трансформера

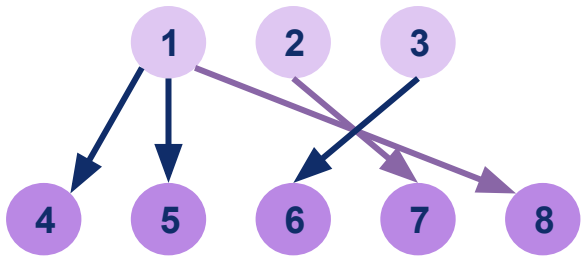


**Гиперпараметры**:

- использовали 1.5M пользователей
- `embedding_dim=256`

# Графовая нейросеть TwHIN

## Ablation study

1. Источник позитивов & айтемный энкодер

| Источник | Предобученный энкодер | Churn | Category | SKU |
|---|---|---|---|---|
| Покупки | - | 0.6083 | 0.6719 | 0.6321 |
| Покупки + Корзина | - | **0.6625** | 0.7048 | 0.6719 |
| Покупки + Корзина | ✔ | 0.6401 | **0.7094** | **0.6815** |

# Deep Cross Network

**Что на вход:**

1. эмбеддинг пользователя из Трансформера
2. счетчики

**Предобработка счетчиков:**

1. каждый счетчик разбивается на 64 бина по квантилям
2. каждый бин разбивается на 32 подбина равномерно. Теперь каждый счетчик закодирован числом от 0 до 64*32-1
3. Каждому значению сопоставляем эмбеддинг размерности 2

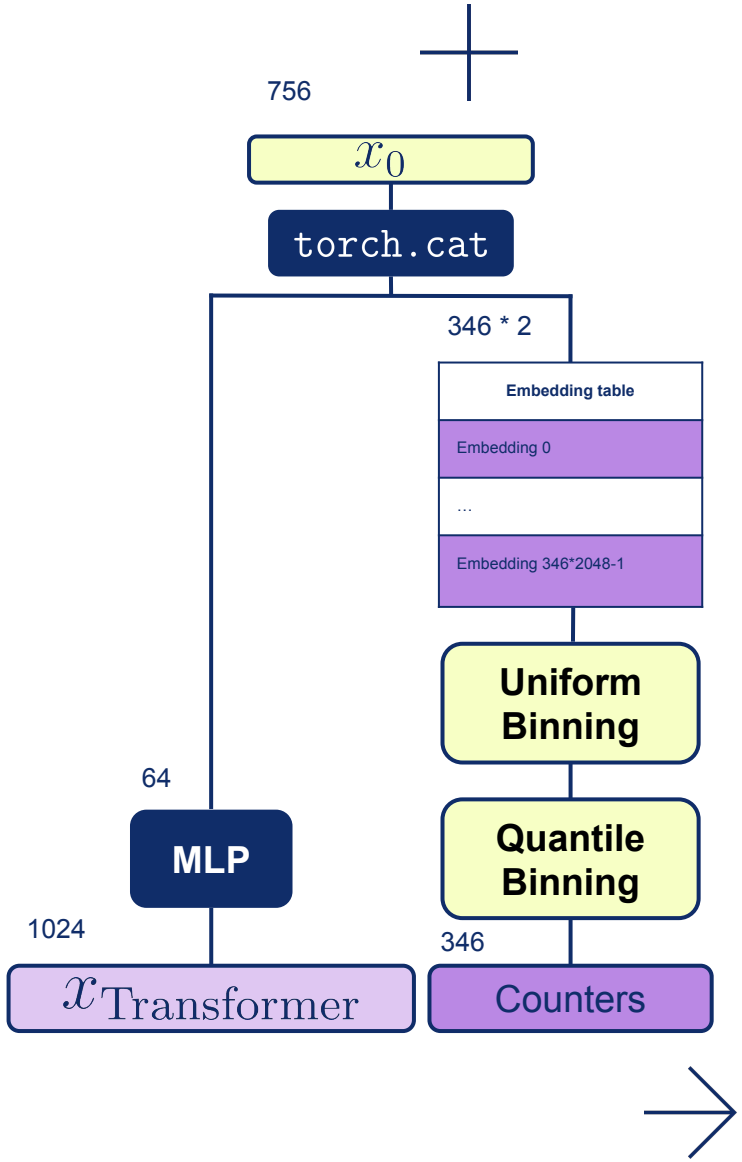

# Deep Cross Network

**Архитектура:**

1. 3 слоя DCN-v2:

$$\mathbf{x}_{l+1} = \mathbf{x}_0 \odot \left(U_l \left(V_l^\top \mathbf{x}_l\right) + \mathbf{b}_l\right) + \mathbf{x}_l, \;\; V_l, U_l \in \mathbb{R}^{d \times r_l}$$

2. 4 слоя DenseNet

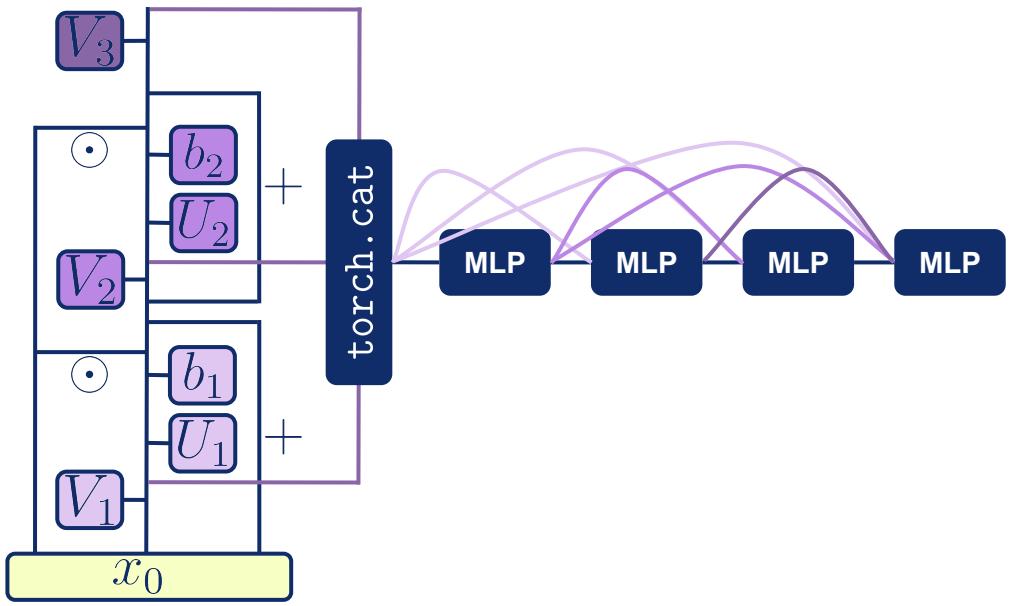


**Функции ошибки:**

1. Churn prediction (Binary Cross-Entropy)
2. SKU propensity prediction (Binary Cross-Entropy)
3. Category propensity prediction
4. (Binary Cross-Entropy)
5. Контрастивное сближение аугментированных историй:

$$\mathcal{L}_{\mathrm{CL}}(p'_u, p''_u) = -\log \frac{e^{\langle p'_u, p''_u \rangle / \tau}}{e^{\langle p'_u, p''_u \rangle / \tau} + \sum_{n \in \mathcal{N}} e^{\langle p'_u, p''_n \rangle / \tau}},$$

$\mathcal{N}$ - in-batch негативы

# Deep Cross Network

**Гиперпараметры:**

- $r_0 = 64, r_1 = r_2 = 32$
- DenseNet: `hidden_dim=64`

**На инференсе:**

- используем выходы DCN-v2 в качестве эмбеддинга пользователя (размерность 128)

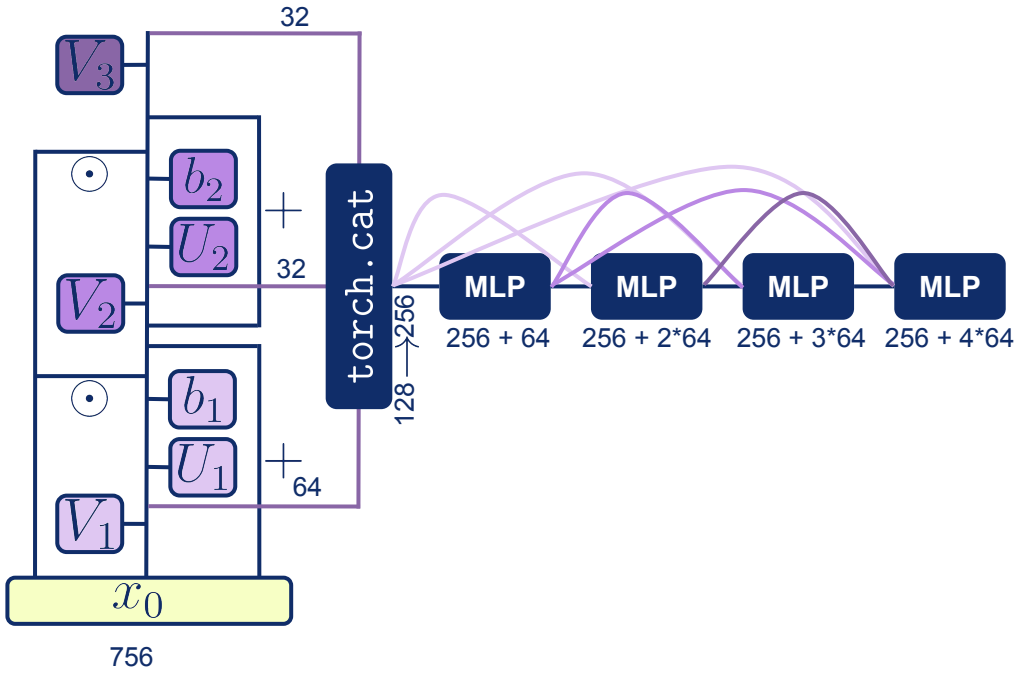

# Deep Cross Network

## Ablation study

1. Нужен ли контрастивный лосс?

| Objectives | Churn | Category | SKU |
|---|---|---|---|
| All objectives | **0.7509** | **0.8115** | **0.7952** |
| W/o CL | 0.7496 | 0.7972 | 0.7862 |

# Результаты соревнования

| Rank | Team | Churn | Category | SKU | hid.1 | hid.2 | hid.3 |
|---|---|---|---|---|---|---|---|
| 1 | rec2 | 0.7375 | 0.8179 | **0.8224** | **0.7717** | **0.8293** | **0.8161** |
| 2 | ai_lab_recsys | 0.7376 | **0.8180** | 0.8130 | 0.7649 | 0.8052 | 0.8117 |
| 3 | SenseLab | 0.7374 | **0.8180** | 0.8081 | 0.7637 | 0.8081 | 0.8116 |
| 4 | **ambitious** | **0.7389** | 0.8151 | 0.8041 | 0.7699 | 0.7948 | 0.8147 |

**Закрытые задачи:**

- **hid.1:** предсказать churn для всех клиентов (в открытой churn задаче были клиенты с хотя бы одной покупкой в открытых данных)
- **hid.2:** предсказать покупку новых товаров, которых не было в открытых данных
- **hid.3:** предсказать, в каком ценовом бакете (их 100) будет покупка

# Решение rec2 [1] (первое место)

1. Contrastive Learning Transformer
2. Multi-task Transformer
3. 166 счетчиков
4. Stacking

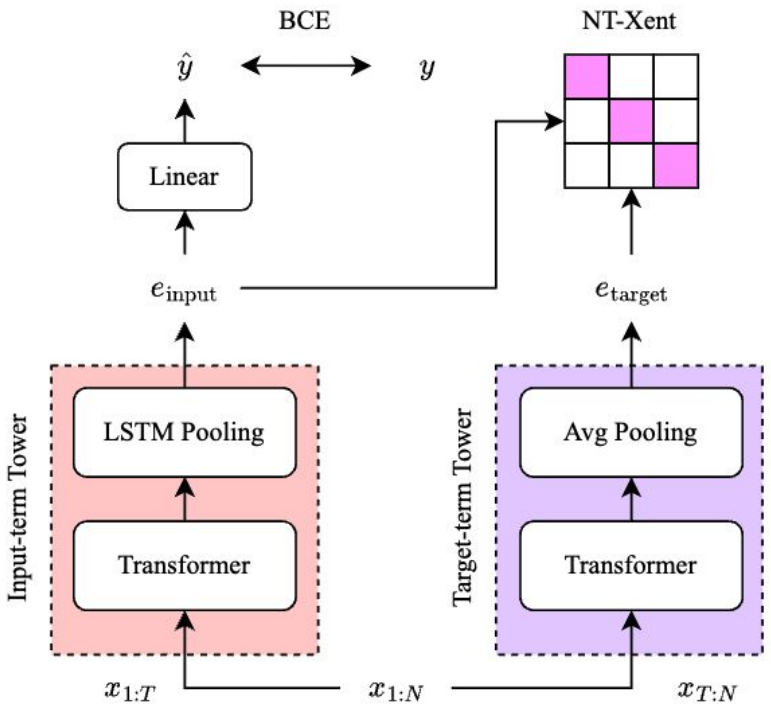


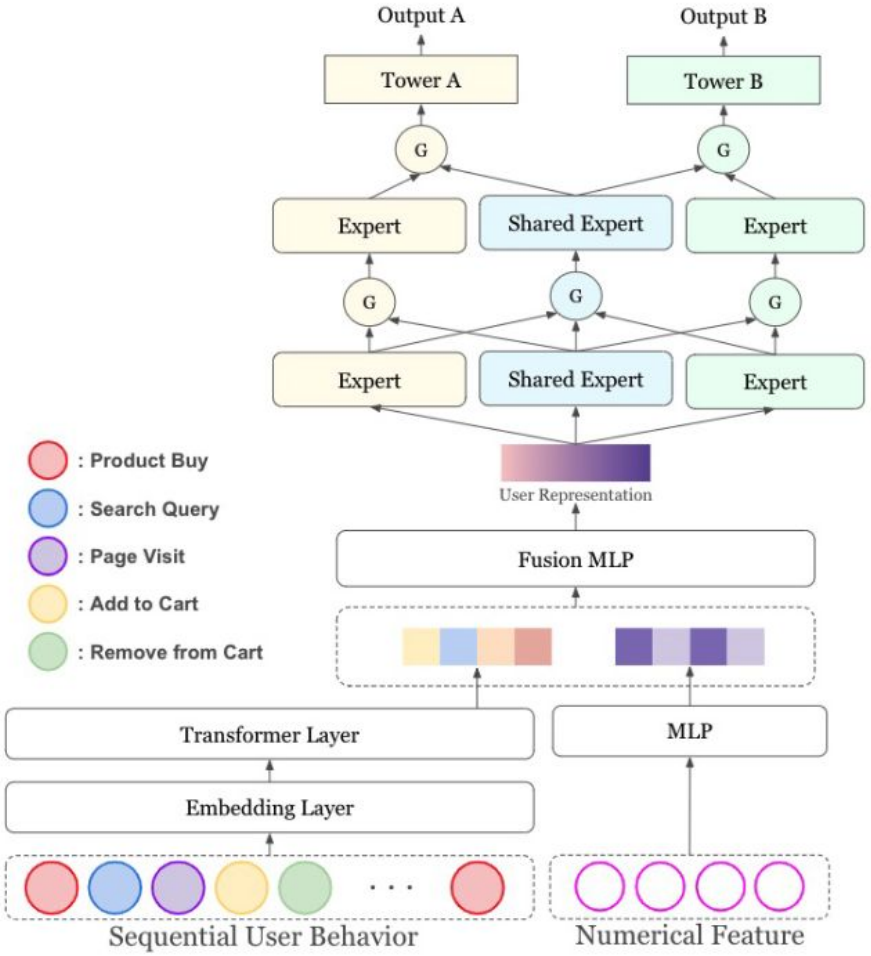


[1] Sawada et al., Toward Universal User Representations: Contrastive Learningwith Transformers and Embedding Ensembles

# Решение ai_lab_recsys [1] (второе место)

1. GRU-based encoder-decoder model
2. iALS, LightFM
3. Transformer-based (GPT-2) Next Product Prediction, Next URL Prediction
4. LLM-based embedding (SmolLM2)
5. Счетчики

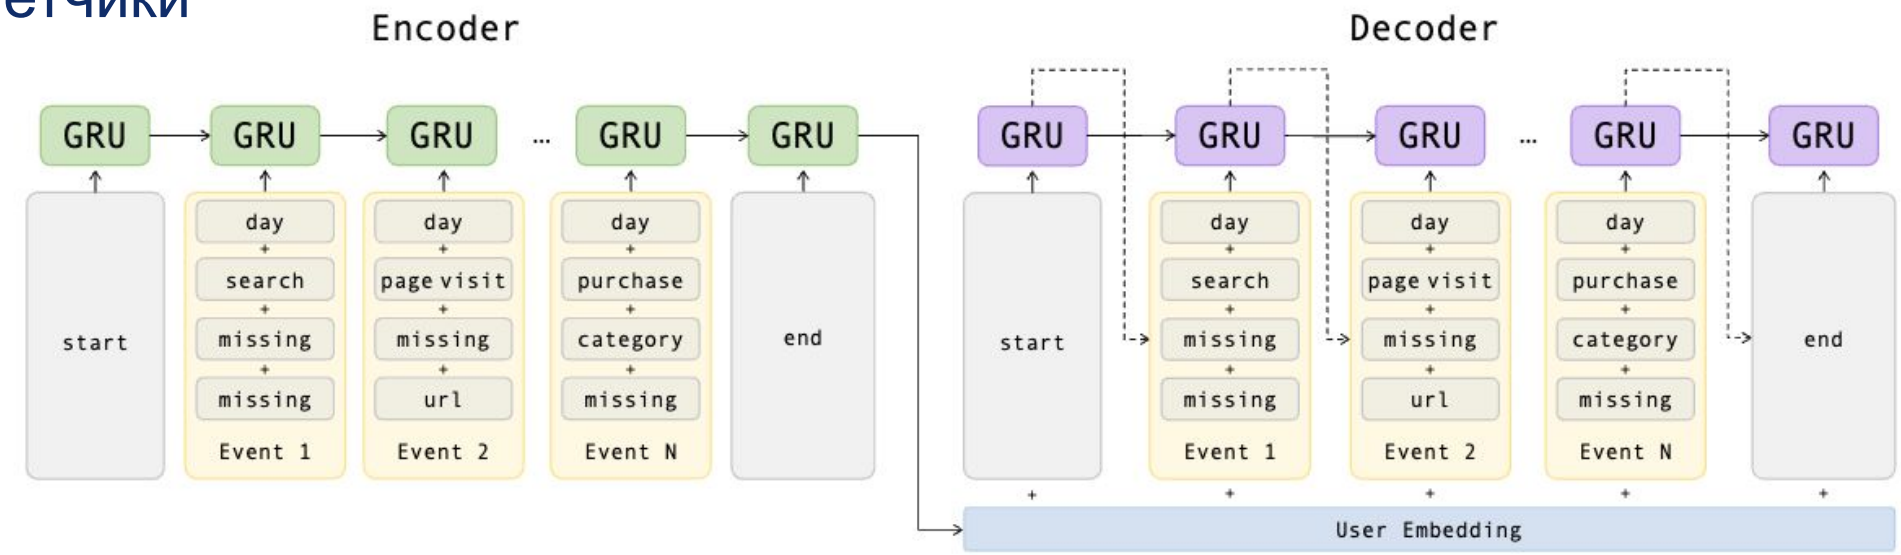


[1] Klenitskiy et al., Encode Me If You Can: Learning Universal User Representationsvia Event Sequence Autoencoding

# Решение SenseLab [1] (третье место)

1. Счетчики
2. RGCN + Multitask Learning (RGCN-MTL): link prediction and node regression
3. RGCN + Timestamp Encoding as Edge Features (RGCN-TSE)
4. Relational Graph Attention Network (RGAT)

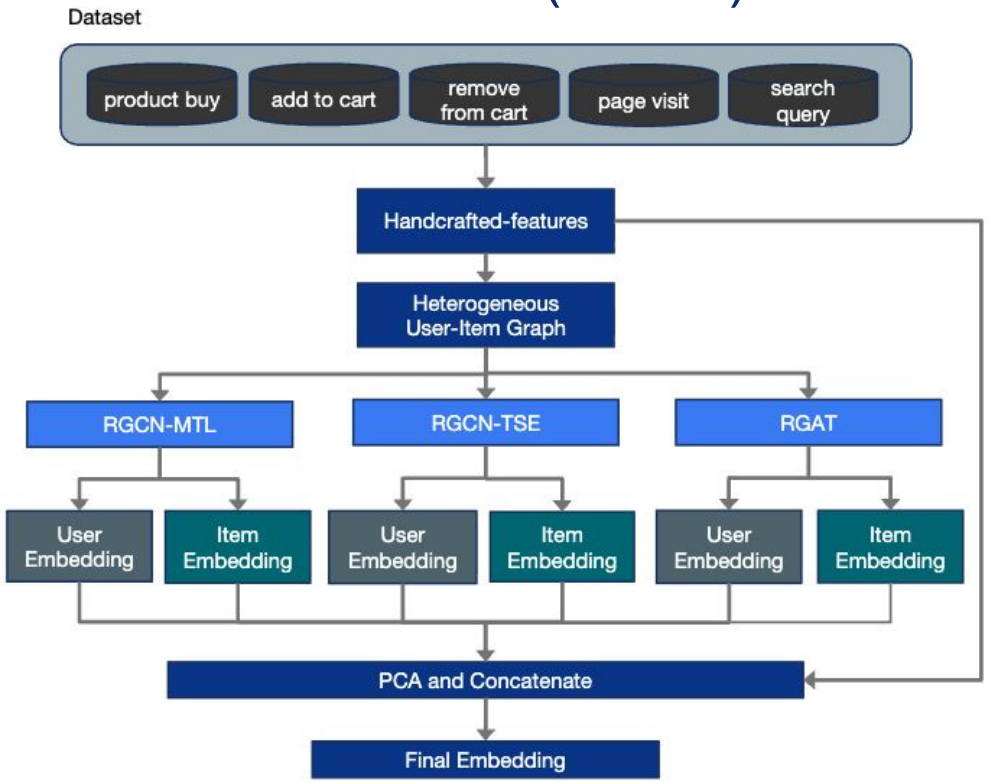


[1] Takimura et al., Universal Behavioral Profiles using Graph Neural Networks

OKH